

Sección 1 — Lectura

Plataforma web para el aprendizaje de idiomas

Documentación técnica: sistema de lectura y pipeline de PLN

Español · Inglés · Alemán | React + Vite · Python · spaCy · FreeDict · opus-mt / Gemini

Documento de referencia para la memoria de tesis y el auto-aprendizaje. Recoge las librerías y modelos empleados, la arquitectura, los pipelines, los errores encontrados y su solución, y las ventajas y desventajas de cada decisión de implementación.

Índice

1. Introducción y objetivos
2. Arquitectura general
3. Frontend (React + Vite)
4. Pipeline de PLN offline (Python)
5. Traducción por oración de libros (LLM vs MT)
6. Errores encontrados y soluciones
7. Ventajas y desventajas de cada implementación
8. Librerías, modelos y recursos
9. Insights y metodología
10. Estado actual y trabajo futuro
11. Glosario técnico

1. Introducción y objetivos

El proyecto es una plataforma web para aprender español, inglés y alemán, concebida como trabajo de tesis en **matemática algorítmica**. La aportación central de la tesis no es la herramienta en sí, sino el **modelado matemático y algorítmico** que la sustenta (procesos estocásticos, modelos de frecuencia léxica, reglas morfológicas, álgebra lineal, teoría de grafos y de números); el sitio es el medio donde esas herramientas viven y se demuestran en funcionamiento.

La plataforma se organiza en cuatro vertientes: (1) **lectura por placer**, (2) **repaso de vocabulario** con repetición espaciada (Leitner como cadena de Markov + SM-2), (3) **gramática** generada con PLN sobre los propios textos, y (4) **juegos** (un Codenames ya desarrollado). Este documento cubre lo construido hasta ahora: la **vertiente de lectura** y su **pipeline de PLN**, además de mejoras al juego existente.

Alcance de lo construido

- Sección de **Lectura** completa: biblioteca por idioma/nivel, lector con traducción por palabra y por frase, bolsa de palabras persistente y seguimiento de progreso.
- **Pipeline de PLN offline** en Python que ingiere libros de dominio público, los procesa con spaCy y genera el JSON que consume el frontend (traducción por palabra y por frase).
- **Motor de lógica pura** con pruebas unitarias (Vitest), germen del núcleo matemático.
- Mejoras al **juego Codenames**: extracción del generador congruencial a un módulo puro, semilla que codifica idioma y nivel, y optimización de recursos.

2. Arquitectura general

El sistema se estructura en tres piezas claramente separadas, siguiendo el diseño de la tesis: un pipeline offline que hace el trabajo pesado, un motor algorítmico puro, y un frontend que solo presenta e interactúa.

Pieza	Tecnología	Responsabilidad
Pipeline offline	Python (spaCy, FreeDict, transformers)	Ingiere textos de dominio público, calcula segmentación, lematización y traducción; exporta JSON. Se ejecuta una sola vez, fuera de línea.
Motor algorítmico	JavaScript puro (+ Vitest)	Lógica sin efectos secundarios: bolsa de palabras, generación determinista del tablero, progreso. Testeable en aislamiento.
Frontend	React 19 + Vite 8 + react-router 7	Consume el JSON precalculado y gestiona presentación e interacción. No ejecuta procesamiento pesado en vivo.

INSIGHT — Principio de diseño: “sin APIs en vivo”

La aplicación en ejecución es **determinista y sin red**: todo el estado vive en `localStorage` y todos los datos (textos, traducciones, léxico) son JSON estático precalculado. El coste computacional (PLN, traducción) se paga una vez en el pipeline, no en cada visita.

Matiz importante: usar un LLM (Gemini) o un modelo de MT para traducir un libro es un **paso offline de una sola vez** que produce JSON estático; no rompe ese principio, porque la app nunca llama a una API en tiempo de ejecución.

Flujo de datos: textos de dominio público (Project Gutenberg) -> pipeline Python (spaCy + diccionarios) -> archivos JSON en `src/data/` -> frontend React que los carga y renderiza. El estado del usuario (bolsa, progreso) se guarda en el navegador.

3. Frontend (React + Vite)

3.1 Stack y versiones

Librería	Versión	Para qué
React	19.2	UI declarativa por componentes.
Vite	8.0	Bundler y servidor de desarrollo (HMR). Rollup/Oxc por debajo.
react-router-dom	7.18	Enrutado por secciones y URLs profundas.
Vitest	4.1	Pruebas unitarias del motor puro.
ESLint	9	Análisis estático.

3.2 Enrutado y secciones

App.jsx pasó de ser el router del juego a un router de **plataforma** con BrowserRouter. Rutas: / (menú), /juegos/* (Codenames), /lectura (biblioteca), /lectura/:idioma/:nivel/:id (lector) y /bolsa. Para que las URLs profundas no den 404 en Netlify se añadió public/_redirects con /* /index.html 200 (fallback SPA).

3.3 Modelo de datos

Cada **lectura** es un JSON con metadatos y el cuerpo alineado por frase entre idiomas. Las lecturas ya no tienen que ser trilingües: pueden ser de+es, en+es, etc.; el español actúa como idioma de traducción. Los libros añaden campos libro/parte/partes para agruparse.

```
{
  "id": "mercado-01", "nivel": "principiante", "autor": "...",
  "titulo": { "es": "El mercado", "en": "The market", "de": "Der Markt" },
  "fuente": "...procedencia y URL de dominio público...",
  "cuerpo": {
    "de": ["Sie kauft Äpfel, Brot und Käse.", ...], // frase i
    "es": ["Compra manzanas, pan y queso.", ...] // frase i (alineada)
  }
}
```

El **léxico** (traducción por palabra) es un mapa idioma:forma -> { lemma, es }. Se busca por la forma superficial normalizada (minúsculas, sin puntuación), conservando acentos y umlauts.

```
{ "de:frau": { "lemma": "Frau", "es": "mujer" },
  "de:kauft": { "lemma": "kaufen", "es": "compra" } }
```

La **bolsa de palabras** es única y persistente; cada entrada guarda id, lang, surface, lemma, traducciones, origen, addedAt. Está diseñada para que el motor de repaso (Sección 2 de la tesis) le agregue después su estado (caja de Leitner, factor SM-2).

3.4 Motor de lógica pura + persistencia

Se separó el **núcleo puro** (sin DOM, React ni localStorage) de la persistencia. Esto es lo que la tesis valora como “motor testeable” y de paso elimina duplicación de código.

- engine/board.js: generador congruencial lineal (LCG), Fisher-Yates, composición/parseo de semilla y generación determinista del tablero.
- engine/bolsa.js: alta/baja en la bolsa. Regla de la tesis: **una palabra ya presente conserva su estado** (no se reinicia el progreso).
- engine/progreso.js: lecturas completadas.
- engine/almacenamiento.js: adaptador delgado (impuro) sobre localStorage.

Pruebas con **Vitest** (17 casos): determinismo del tablero (misma semilla -> mismo resultado, distribución 9/8/7/1), la regla de no-reinicio de la bolsa, normalización, etc.

INSIGHT — El LCG como puente con la teoría de números

El juego sincroniza los tableros de ambos equipos con un **generador congruencial lineal** sembrado por un hash de la semilla. La semilla se rediseñó a formato XX-YYYY, donde XX codifica idioma y nivel del vocabulario; así el capitán solo introduce la semilla y el sistema deduce el diccionario. Esto conecta con aritmética modular y teoría de números, tal como plantea la tesis.

3.5 Experiencia de lectura

- **Tokenización** por expresión regular Unicode (`\p{L}...`) que separa palabras clicables de la puntuación, conservando el texto original.
- **Traducción por palabra:** al tocar una palabra se busca en el léxico y se muestra un popup con la traducción al español y un botón para añadirla a la bolsa.
- **Traducción por frase:** un marcador discreto en el margen de cada frase revela su traducción alineada. Se eligió un objetivo **táctil** (no hover) para que funcione en móvil; el hover es solo una mejora en escritorio.
- **Libros:** las partes de un libro colapsan en una sola tarjeta con progreso “N/10 partes”; el lector ofrece navegación anterior/siguiente y “finalizar y continuar”.
- **Bolsa y progreso** persistentes en localStorage; la biblioteca conserva idioma y nivel en la URL para no reiniciarse al volver de una lectura.

3.6 Carga de datos y peso del bundle

El catálogo carga todas las lecturas automáticamente con `import.meta.glob`, de modo que añadir lecturas (a mano o desde el pipeline) no requiere tocar código. El **léxico** (465 KB, 5.779 entradas) se importaba de forma estática e inflaba el bundle inicial; se pasó a **carga bajo demanda** con `dynamic import`, que Vite emite como chunk aparte cacheado, descargado solo al abrir una lectura. Bundle inicial: **1018 KB -> 694 KB** (gzip 328 -> 253 KB).

4. Pipeline de PLN offline (Python)

El pipeline vive en `pipeline/` y convierte libros de texto plano en las lecturas JSON que consume el frontend. Está separado en dos pasos: **ingesta** de un libro (`procesar.py`) y **construcción del léxico** sobre todas las lecturas (`construir_lexico.py`).

4.1 spaCy: segmentación, tokenización, lematización

Se usa **spaCy** con los modelos `de_core_news_md` (alemán) y `en_core_web_sm` (inglés). spaCy segmenta el texto en frases, tokeniza y asigna a cada token su lema, categoría gramatical (POS), rasgos morfológicos y relaciones de dependencia. El pipeline aprovecha las **frases** (para alinear traducciones) y los **lemas** (para buscar en el diccionario).

INSIGHT — Verbos separables del alemán vía la dependencia svp

El alemán parte muchos verbos: “...bereit **et** ... **vor**” es el verbo **vorbereiten** (preparar). spaCy etiqueta el prefijo con la dependencia svp (separable verb prefix) apuntando al verbo. El pipeline lo detecta y **reconstruye** el lema real: `vor + bereiten = vorbereiten`, y hace que tocar cualquiera de las dos partes remita a la misma entrada. Esto resuelve automáticamente un caso que al principio hubo que corregir a mano.

Es un buen ejemplo de la tesis: usar el **análisis de dependencias** para resolver una ambigüedad morfológica de forma algorítmica.

4.2 Traducción por palabra: diccionarios FreeDict por capas

La traducción por palabra es **determinista y offline**. Se usan diccionarios libres de **FreeDict** (formato TEI/XML) y una estrategia por capas en `traductor.py`:

Capa	Método	Marca
1. Directo	deu-spa (36.744 entradas), por lema y por forma	—
2. Cadena	deu-eng (~380 mil) -> eng-spa (~59 mil) cuando deu-spa falla	(vía inglés)
3. Compuesto	cabeza del compuesto alemán (sufijo de >= 3 letras)	(en compuesto)

El diccionario deu-spa por sí solo cubría ~70% del vocabulario de un libro; le faltan muchas palabras comunes (unruhig, hilflos, bogenförmig...). La **cadena por inglés** (FreeDict deu-eng es enorme) cierra la mayor parte del hueco, aunque a costa de dos saltos y algo de ruido; por eso se marca "(vía inglés)". La **descomposición de compuestos** (la cabeza de un compuesto alemán es el último elemento: Holztür -> Tür -> puerta) recupera compuestos ausentes.

4.3 Cobertura de traducción y su evolución

La **cobertura** es el porcentaje de formas de palabra distintas que reciben traducción. Se midió con un diagnóstico que clasifica los fallos por categoría gramatical (`diagnostico.py`). Evolución sobre *Die Verwandlung*:

Cambio	Cobertura
FreeDict deu-spa + modelo pequeño (sm)	70%
Modelo mediano (md): mejor lematización (abhielt -> abhalten)	81%
Cadena deu-eng -> eng-spa	90%
Descomposición de compuestos con cabezas de 3 letras	92%

El ~8% restante son sobre todo **verbos fuertes** que spaCy no lematiza bien (hing, dasaß) y compuestos raros. Para **principiante e intermedio** se alcanzó el **100%**: el léxico se reconstruye desde una **semilla curada a mano** (`lexico.base.json`) que además de las entradas del pipeline incluye 49 casos rellenados manualmente (nombres propios marcados como tal, imperativos como Komm/gib, y verbos fuertes como schlief/aß).

NOTA — Fusión idempotente del léxico

`construir_lexico.py` reconstruye el léxico completo desde la semilla curada más el vocabulario de todas las lecturas, de modo que re-ejecutar el pipeline es **idempotente** y no arrastra entradas obsoletas. Al fusionar, **nunca sobrescribe** una entrada ya traducida con una sin traducción (una misma forma puede recibir distinto lema según el contexto).

4.4 Ambigüedad y overrides por lectura

Un léxico global (clave idioma:forma) no puede desambiguar formas que dependen del contexto: *nahm* es parte de **annehmen** (suponer) en una fábula, pero es **nehmen** (tomar) en otra novela; *an* es partícula separable o preposición según la frase. Es el **sub-problema de ambigüedad** que la tesis plantea explícitamente (una misma forma admite varios análisis).

Solución adoptada: cada lectura puede llevar un pequeño mapa `lexico` con overrides que el frontend **prioriza** sobre el léxico global. Para los textos curados de principiante/intermedio se detectaron los verbos separables (dependencia svp) inequívocos dentro de cada texto y se fijó a mano el lema y la traducción correctos, verificados frase a frase.

INSIGHT — Por qué un léxico global no basta

El límite es de fondo: la traducción por palabra correcta depende de la **posición del token**, no solo de su forma. Los overrides por lectura resuelven los casos curados; la solución general sería anotar el léxico **por token** en el pipeline (algo que spaCy ya permite) y renderizar con esos tokens en vez de tokenizar en el cliente. Es un refactor mayor, anotado como trabajo futuro.

5. Traducción por oración de libros (LLM vs MT)

Los libros de nivel avanzado solo traen el texto original; darles traducción **por frase** exige una versión española **alineada 1:1** con las frases alemanas (la frase es[i] corresponde a de[i]). Esa alineación es la restricción que manda en todas las opciones. Se implementaron dos vías.

5.1 Vía LLM (Gemini) — máxima calidad, semi-manual

Flujo con validación de alineación: `exportar_frases.py` vuelca las frases numeradas + un prompt estricto (“una línea por oración, no unir ni dividir”); se pega en Gemini; `importar_traducccion.py` parsea la respuesta y **valida 1:1** (si el conteo o la numeración no cuadran, no escribe nada). Así se tradujo *Die Verwandlung* de Kafka (10 partes, 864 oraciones, todas validadas).

5.2 Vía MT offline (opus-mt) — automática, sin API

Alternativa totalmente automática con **opus-mt** (Helsinki-NLP, modelos Marian) vía transformers, traducción directa de->es. La alineación 1:1 es automática (una salida por frase). Antes se descartó **Argos Translate**, que no tiene de->es directo y **pivota por inglés** (de->en->es), con errores graves. Con MT se tradujo *Immensee* de Theodor Storm (10 partes) sin copia-pegar.

5.3 Comparación de calidad

Frase alemana	Gemini	opus-mt (directo)	Argos (pivote)
...einem ungeheueren Ungeziefer verwandelt	convertido en un monstruoso insecto	convirtiéndose en una bestia monstruosa	monstruoso vértigo (mal)
bestäubt (polvoriento)	cubiertos de polvo	polinizados (mal)	—
wohlgekleideter Mann	hombre bien vestido	vestido y vestido (mal)	—

Conclusión práctica: la MT offline **automatiza todo** el flujo pero comete errores semánticos que un LLM no comete. Para libros donde importe la calidad, conviene el LLM; para volumen o cuando la calidad “suficiente” basta, la MT. Ambas producen JSON estático, así que la app sigue siendo offline.

6. Errores encontrados y soluciones

Esta sección recoge los tropiezos del proceso; es la parte más útil para aprender, porque muchos son problemas de entorno o de comprensión de las librerías, no de la lógica.

ERROR / SOLUCIÓN — Certificados SSL en git (y luego en Python)

Síntoma: `git push` y las descargas de Python fallaban con “unable to get local issuer certificate”.

Causa: el entorno intercepta TLS y el almacén de certificados de OpenSSL/git no tenía el certificado raíz.

Solución: en git, `http.sslBackend=schannel` (usa el almacén de Windows, que se mantiene actualizado solo). En Python, instalar `pip-system-certs`, que hace que `requests` use también el almacén de Windows (necesario para descargar los modelos de spaCy, los diccionarios y los modelos de traducción).

ERROR / SOLUCIÓN — Reglas de los Hooks de React

Síntoma: riesgo de romper el orden de los hooks en TableroClave, que tenía un return de error antes de los useState.

Solución: mover **todos** los hooks al principio del componente y dejar los return condicionales después. Los hooks deben ejecutarse siempre en el mismo orden en cada render.

ERROR / SOLUCIÓN — useEffect disparado por un “gatillo falso”

Síntoma: para re-generar el tablero al cambiar de ronda se incrementaba un estado numeroRonda solo para forzar el useEffect.

Solución: extraer una función iniciarPartida() llamada explícitamente (en el montaje y al pasar de ronda). Intención explícita en vez de estado artificial.

ERROR / SOLUCIÓN — spaCy sobre-segmentaba las frases

Síntoma: Die Verwandlung daba 2.666 “frases” (Kafka usa frases largas; eran fragmentos).

Causa: el texto de Gutenberg viene con **líneas envueltas** (un salto de línea cada ~70 caracteres); spaCy segmentaba por esos saltos.

Solución: unir todas las líneas en un flujo continuo antes de segmentar (quitando además los marcadores de capítulo). Resultado: 864 frases reales.

ERROR / SOLUCIÓN — Compuestos y verbos fuertes sin traducción

Síntoma: ~19% de palabras sin traducción; muchos compuestos (Musterkollektion) y formas verbales (hing, dasaß).

Solución: cadena de->en->es con el enorme diccionario deu-eng, descomposición de la cabeza del compuesto, y modelo spaCy mediano para mejores lemas. Cobertura 70% -> 92%. Los verbos fuertes restantes exigirían un analizador morfológico más potente (rendimientos decrecientes).

ERROR / SOLUCIÓN — MT por pivote confundía el sentido

Síntoma: Argos traducía “Ungeziefer” (insecto) como “vértigo”.

Causa: Argos no tiene de->es directo; pivota por inglés y el doble salto acumula errores de sentido.

Solución: usar opus-mt directo de->es (Helsinki-NLP), que no pivota y da traducciones sin ese tipo de error grave.

ERROR / SOLUCIÓN — Codificación de consola y shell en Windows

Síntoma: los umlauts salían como cajas o daban UnicodeEncodeError (cp1252); y en cierto momento el shell de Bash se quedó sin PATH (ni ls funcionaba).

Solución: ejecutar Python con PYTHONUTF8=1 (fuerza UTF-8 en E/S) y escribir siempre el JSON con ensure_ascii=False; y cambiar a PowerShell cuando Bash falló. Los datos siempre estuvieron bien (UTF-8); era solo la **visualización**.

ERROR / SOLUCIÓN — Imágenes enormes (rendimiento)

Síntoma: la imagen del hero pesaba **19 MB** (5192x3072).

Solución: redimensionar a 1600 px y convertir a WebP con sharp: 19 MB -> 46 KB (-99,75%). También se redujo el favicon (PNG de 200 KB -> 19 KB) y se corrigió su declaración type.

7. Ventajas y desventajas de cada implementación

7.1 Traducción por oración: LLM (Gemini) vs MT offline (opus-mt)

Criterio	LLM (Gemini)	MT offline (opus-mt)
Calidad	Muy alta, literaria	Buena, con errores semánticos
Automatización	Semi-manual (copia-pegar)	Total (script)
Coste / dependencia	Requiere el LLM (aunque offline: 1 vez)	Modelo local ~300 MB; CPU
Alineación 1:1	Hay que validarla (prompt + verificador)	Automática (una salida por frase)
Escalabilidad	Limitada por el copia-pegar	Alta (miles de frases)

7.2 Traducción por palabra: capas del traductor

Capa	Ventaja	Desventaja
Directo deu-spa	Mejor calidad y precisión	Cobertura limitada (~70%)
Cadena de->en->es	Gran cobertura (deu-eng es enorme)	Dos saltos: ruido y pérdida de sentido; se marca
Cabeza de compuesto	Recupera compuestos ausentes	Aproximada; puede errar (Handschuh)

7.3 Otras decisiones

Decisión	Ventaja	Desventaja
Texto paralelo para traducir la frase	Determinista, sin API; sirve para gramática futura	Sólo frase, no palabra; hay que alinear
Léxico para traducir la palabra	Traducción por palabra offline y precisa	No capta contexto; requiere el pipeline
localStorage para el estado	Cero backend; privado; simple	No sincroniza entre dispositivos
Modelo spaCy md vs sm	Mejor lematización (etiquetado más preciso)	Más peso y algo más lento
Léxico por dynamic import	Bundle inicial mucho menor; cacheado	Pequeña latencia al abrir la primera lectura

8. Librerías, modelos y recursos

8.1 Frontend

Recurso	Licencia	Uso
React 19 / react-dom	MIT	UI por componentes
Vite 8	MIT	Bundler + dev server
react-router-dom 7	MIT	Enrutado y URLs
Vitest 4	MIT	Pruebas del motor puro
sharp (dev, puntual)	Apache-2.0	Optimización de imágenes (WebP)

8.2 Pipeline de PLN

Recurso	Licencia	Uso
spaCy + de_core_news_md / en_core_web_sm	MIT	Segmentación, tokenización, lematización, dependencias

Recurso	Licencia	Uso
FreeDict deu-spa / deu-eng / eng-spa (TEI)	Libre (GPL/CC)	Traducción por palabra (directo + cadena)
transformers + torch	Apache-2.0 / BSD	Ejecutar opus-mt
Helsinki-NLP/opus-mt-de-es (Marian)	CC-BY / Apache	MT por frase de->es (offline)
Argos Translate (evaluado, descartado)	MIT/CC	MT por pivote; peor calidad para de->es
pip-system-certs	BSD	Usar el almacén de certificados de Windows (SSL)
Project Gutenberg (textos)	Dominio público	Corpus de lectura (Kafka, Storm, Esopo, Grimm)

8.3 Modelos: notas de tamaño y calidad

- **de_core_news_md**: modelo mediano alemán; mejor etiquetado/lematización que el pequeño. Clave para reducir errores de lema.
- **opus-mt-de-es**: ~300 MB; inferencia en CPU; directo (sin pivote).
- Las dependencias pesadas de MT (transformers/torch) y los modelos **no** se versionan en git; se documentan y se cachean fuera del repo. Solo se versiona el JSON de salida.

9. Insights y metodología

- **Separar lo puro de lo impuro.** Extraer la lógica (LCG, bolsa, progreso) a módulos sin efectos secundarios permitió probarla con Vitest y reutilizarla; el patrón se repitió en el pipeline (traductor, construir_lexico).
- **Medir antes de optimizar.** El diagnóstico de cobertura por POS reveló que el problema no era la lematización sino el **tamaño del diccionario**; eso orientó la solución (cadena por inglés) en vez de perseguir mejoras marginales del lematizador.
- **Validar la alineación siempre.** El verificador 1:1 del importador de traducciones convirtió un paso frágil (pegar la salida de un LLM) en algo seguro: si algo no cuadra, no escribe nada.
- **Formatos “pipeline-ready”.** Diseñar el JSON desde el principio con el formato que emitiría el pipeline evitó rehacer el frontend cuando este llegó.
- **Diferenciar problema de datos y problema de visualización.** Muchos “errores” (umlauts como cajas) eran solo codificación de consola; los datos estaban bien.
- **Procedencia y licencias.** Cada lectura guarda su campo fuente con la obra, el autor y la URL de dominio público: transparencia para la tesis.

10. Estado actual y trabajo futuro

Hecho

- Sección de Lectura completa (biblioteca, lector, bolsa, progreso, libros por partes).
- Pipeline de PLN: ingesta, spaCy, traducción por palabra (92% en libros; 100% en principiante/intermedio) y por frase (Gemini y MT).
- Contenido: 9 lecturas cortas trilingües + 2 libros completos (Die Verwandlung, Immensee).
- Motor puro con pruebas; juego Codenames refactorizado; recursos optimizados.

Pendiente / próximos pasos

- **Sección 2 (Repaso):** repetición espaciada (Leitner como cadena de Markov + SM-2, opcional FSRS) sobre la bolsa; es el núcleo matemático de la tesis.

- **Sección 3 (Gramática):** ejercicios cloze generados con spaCy (Matcher / DependencyMatcher) sobre los propios textos; distractores por similitud coseno de embeddings (álgebra lineal).
- **Más juegos:** word ladder (BFS en grafo de palabras), crucigramas (backtracking), sudoku de palabras (cuadrados latinos).
- **Optimización adicional del peso:** separar metadatos del contenido para cargar las lecturas también bajo demanda; dividir el léxico por idioma/libro.
- **Mejorar cobertura y MT:** analizador morfológico para verbos fuertes; evaluar modelos de MT mayores.

11. Glosario técnico

Término	Definición
PLN / NLP	Procesamiento de Lenguaje Natural.
spaCy	Librería de PLN en Python (segmentación, POS, lemas, dependencias).
Lema / lematización	Forma de diccionario de una palabra (kauft -> kaufen).
POS	Part-of-speech: categoría gramatical (VERB, NOUN, ADJ...).
Dependencia svp	Etiqueta de spaCy para el prefijo de un verbo separable alemán.
Verbo separable	Verbo alemán cuyo prefijo se desplaza (bereitet ... vor = vorbereiten).
FreeDict	Colección de diccionarios bilingües libres en formato TEI (XML).
TEI	Text Encoding Initiative: estándar XML para textos y diccionarios.
MT	Machine Translation (traducción automática).
opus-mt / Marian	Modelos de MT abiertos de Helsinki-NLP.
LLM	Large Language Model (p. ej. Gemini).
Alineación 1:1	Correspondencia frase a frase entre el original y su traducción.
LCG	Linear Congruential Generator: generador pseudoaleatorio (aritmética modular).
Fisher-Yates	Algoritmo para barajar un arreglo de forma uniforme.
SPA / bundle	Single Page Application; bundle: JS empaquetado que se descarga.
dynamic import	Carga de un módulo bajo demanda; genera un chunk aparte en Vite.
Cobertura de traducción	% de formas de palabra distintas que reciben traducción.
Leitner / SM-2 / FSRS	Algoritmos de repetición espaciada para el repaso.

Documento generado con ReportLab a partir del historial de desarrollo del proyecto *indescifrable*. Repositorio: github.com/Eduard-Cini/indescifrable.