

Sección 1 — Lectura

Reporte de métricas

Plataforma de idiomas — sistema de lectura trilingüe y pipeline de PLN

Métricas cuantitativas para la memoria de tesis, calculadas sobre el contenido y el código reales del proyecto.

1. Corpus trilingüe

El corpus consta de **144 lecturas** (3 principiante, 49 intermedio, 92 avanzado), incluyendo **10 libros** de dominio público troceados en 134 partes. Cada lectura tiene un **idioma de estudio**: alemán o inglés en las lecturas traducidas, y español en los libros difíciles pensados para nativos (donde el español es el original, no la traducción).

Idioma de estudio	Lecturas	Frases	Tokens	Tipos	TTR
alemán	30	1,811	30,302	5,384	0.178
inglés	58	5,089	96,432	10,850	0.113
español	56	4,880	91,106	14,202	0.156

La razón tipo/token (TTR) baja en alemán/inglés refleja la repetición de vocabulario en las novelas; en español es más alta porque los libros elegidos (*Quijote*, *Buscón*, *Azul*, *Quiroga*) tienen un léxico deliberadamente rico y variado.

2. Cobertura de traducción por palabra (alemán, inglés)

La **cobertura** es el porcentaje de *tipos* (formas distintas) con traducción al español. La **densidad** práctica que ve el usuario es aún mayor porque las formas frecuentes —las que más se tocan— están cubiertas.

Idioma	Nivel	Tipos con traducción / totales	Cobertura
alemán	Principiante	117 / 117	100%
alemán	Intermedio	789 / 789	100%
alemán	Avanzado	11568 / 12181	94%
inglés	Intermedio	21961 / 23753	92%
inglés	Avanzado	13152 / 14507	90%

Principiante e intermedio alcanzan cifras muy altas gracias a la semilla curada y a los overrides por lectura; los libros avanzados quedan algo por debajo (los fallos restantes son verbos fuertes que spaCy no lematiza y compuestos raros). El inglés parte con ventaja: es todo ASCII y el diccionario FreeDict eng-spa es directo.

3. Contribución de cada capa del traductor (alemán)

Descomposición de las traducciones del léxico alemán según la capa que las resolvió (directo FreeDict, cadena por inglés, o cabeza de compuesto).

Capa	Entradas	% de las traducidas
Directo (FreeDict deu-spa)	3,738	76%
Cadena deu-eng -> eng-spa	660	13%
Cabeza de compuesto	490	10%
Total con traducción (de)	4,888	100%

Léxico total: **15,790 entradas** (5,374 de + 10,190 en + 226 es). El inglés->español cubre 8956/10190 por FreeDict directo; el español son voces glosadas a mano (sección 5).

4. Desambiguación de verbos separables (overrides por lectura)

El léxico global no puede distinguir formas dependientes del contexto (p. ej. *nahm* = *annehmen* vs *nehmen*). Se añadieron **19 overrides por lectura** en 7 textos de principiante/intermedio, curados a mano y verificados frase a frase, que el frontend prioriza sobre el léxico global.

5. Glosado monolingüe del español (voces raras)

Para los libros en español —la lengua materna del usuario— no se traduce: se **glosa** con una definición en español moderno solo las **voces poco comunes o arcaicas** (las corrientes no necesitan glosa). La rareza se decide con la frecuencia general del español (escala Zipf, biblioteca wordfreq) y las definiciones se curan a mano en `glosas_es.json`. La métrica es la **densidad de glosado**: tipos glosados sobre el total (no se busca el 100%).

Libro (español)	Tipos glosados	Tipos totales	Densidad
Azul...	67	11192	0.6%
La vida del Buscón (selección)	85	3363	2.5%
Don Quijote de la Mancha (selección)	125	2524	5.0%
Cuentos de amor de locura y de muerte	107	21744	0.5%

El glosario curado tiene **226 entradas de forma** derivadas de ~190 voces base. La densidad es mayor en el Siglo de Oro (Quijote, Buscón: léxico arcaico) que en los textos modernos (Azul, Quiroga), donde un nativo desconoce menos palabras. El glosario es ampliable: añadir entradas sube la densidad sin tocar código.

6. Traducción por oración / glosado (por libro)

Libro	Autor	Idi.	Partes	Frases	Método	Alin.
Azul...	Rubén Darío	es	13	1164	glosa de voces raras	—
La vida del Buscón (selección)	Francisco de Quevedo	es	5	399	glosa de voces raras	—
A Christmas Carol	Charles Dickens	en	20	1784	opus-mt en->es	1:1
Death in Venice	Thomas Mann	en	13	1159	opus-mt en->es	1:1
Immensee	Theodor Storm	de	10	842	opus-mt de->es	1:1
Don Quijote de la Mancha (selección)	Miguel de Cervantes	es	2	161	glosa de voces raras	—

Libro	Autor	Idi.	Partes	Frases	Método	Alin.
Cuentos de amor de locura y de muerte	Horacio Quiroga	es	36	3156	glosa de voces raras	—
The Time Machine	H. G. Wells	en	22	1907	opus-mt en->es	1:1
The Fall of the House of Usher	Edgar Allan Poe	en	3	239	opus-mt en->es	1:1
Die Verwandlung	Franz Kafka	de	10	864	Gemini (LLM)	1:1

Los libros de alemán/inglés tienen traducción por frase con alineación **1:1 verificada** (el validador no escribe nada si el conteo no cuadra); los de español no llevan traducción por frase (son monolingües: el foco es la palabra).

7. Calidad del transformer (MT) frente al LLM de referencia

Se tradujo la **Parte 1 de Die Verwandlung** (90 frases) con **opus-mt** y se comparó con la traducción de **Gemini** (referencia). Métricas de similitud automática:

Métrica	Valor	Interpretación
chrF (F-score de n-gramas de carácter, beta=2)	61.9	0-100; mide solape de caracteres. Traducciones aceptables suelen dar 40-60.
F1 de tokens (solape de palabras)	62.7	0-100; solape léxico bruto con la referencia.

Lectura de los números: la MT recupera una parte sustancial del contenido de la referencia, pero **no es una medida de calidad absoluta** (Gemini no es verdad de oro, y dos traducciones correctas pueden diferir mucho en palabras). Cualitativamente la MT comete errores semánticos que el LLM no. El mismo motor opus-mt, con el modelo en->es, tradujo automáticamente los cuatro libros ingleses.

8. Motor algorítmico (pruebas)

El núcleo de lógica pura se prueba con **Vitest** (toda la plataforma: 161 casos). En la sección de lectura y su almacenamiento:

Módulo	Qué verifican las pruebas
board.js (LCG + tablero)	Determinismo: misma semilla -> mismo tablero; distribución exacta 9/8/7/1; parseo de semilla.
bolsa.js	Alta sin duplicar; regla “palabra existente conserva su estado”; normalización con acentos/umlauts.
progreso.js	Marcar/consultar lecturas completadas.
almacenamiento.js	Idioma de estudio y perfil export/import (round-trip sin pérdidas).

9. Resumen de volumen

Concepto	Cantidad
Lecturas (total)	144
Libros completos o en fragmento	10
Frases (de / en / es)	1,811 / 5,089 / 4,880
Entradas de léxico	15,790 (5,374 de, 10,190 en, 226 es)
Overrides por lectura (separables)	19

Concepto	Cantidad
Idiomas de estudio	3 (de, en, es)

Métricas calculadas automáticamente por docs/generar_metricas_seccion1.py sobre el estado actual del repositorio.
chrF/F1 implementados sin dependencias externas.