

Sección 3 — Gramática

Métricas: formalización del generador de cloze, distractores híbridos paradigma/coseno y conteos del corpus

1. El problema formal

Un ejercicio cloze es una tupla (c, r, D) : un contexto c con un hueco, la respuesta r y un conjunto D de k distractores. Para que el ejercicio **mida** la regla gramatical que se enseña, hacen falta dos propiedades en tensión:

(P1) Unicidad: sustituir el hueco por cualquier $d \in D$ debe producir una frase agramatical (o, en separables, un verbo inexistente). Si algún d produce una frase válida, el ejercicio no tiene respuesta y penaliza al alumno que sí sabe la regla.

(P2) Dificultad: los distractores deben ser *plausibles*. Un distractor absurdo se descarta sin saber gramática, y el ejercicio no discrimina.

El generador maximiza P2 **sujeto a** P1: la similitud coseno ordena por plausibilidad (P2) y los filtros por tema garantizan la agramaticalidad (P1).

2. El método híbrido

2.1 El paradigma define el conjunto

Para cada tema, el conjunto de candidatos $C(r)$ sale del paradigma morfológico, no del espacio vectorial completo: las otras 5 formas del artículo definido; las preposiciones del caso opuesto; las formas del mismo lema verbal atestiguadas en el corpus (índice invertido lema $\rightarrow$ formas del léxico de la Sección 1); los prefijos separables del inventario. Esto garantiza que todo candidato sea *categorialmente* comparable con la respuesta — cosa que el coseno por sí solo no da: los vecinos vectoriales de «der» incluyen sustantivos y adverbios, no solo artículos.

2.2 El coseno ordena el conjunto

Con los vectores de spaCy de `core_news_md` (20.000 palabras $\times$ 300 dimensiones), cada candidato se puntúa contra la respuesta y se eligen los $k = 3$ de mayor similitud (*hard negatives*). Empates $\rightarrow$ orden alfabético, así el generador es determinista.

```
cos(u, v) = (u · v) / (||u|| · ||v||) ∈ [-1, 1]
D = top-k según cos(v_r, v_d), d ∈ C(r), filtrado por P1
```

Intuición geométrica: dos formas del mismo paradigma que aparecen en contextos parecidos («dem»/«den», «mit»/«bei») tienen vectores cercanos; el alumno solo puede separarlas aplicando la regla, no por rareza distribucional. Eso es exactamente lo que quiere P2.

3. Los filtros de unicidad (P1), como predicados

Cada tema instancia P1 con un predicado verificable mecánicamente:

Tema	Predicado sobre el candidato d
Declinación	d difiere de r en caso/género/número por construcción del paradigma; el contexto (sustantivo + sintaxis) fija esos rasgos → d agramatical
Preposición	$\text{rige}(d) \neq \text{rige}(r)$ (caso opuesto) $\wedge$ el sintagma tiene marca de caso visible ($\exists$ DET/ADJ/PRON declinado en el subárbol) → d incompatible con la marca
Conjugación	re-parseada la frase con d en el hueco: $\neg \text{finito}(d) \vee \text{persona}(d) \neq \text{persona}(\text{sujeto}) \vee \text{número}(d) \neq \text{número}(\text{sujeto})$. Un d que concuerda (mismo verbo en otro tiempo: ging → geht) daría frase válida y se excluye
Separables	atestiguado(r + lema) en el léxico $\wedge$ $\neg \text{atestiguado}(d + \text{lema})$: la respuesta forma un verbo real del corpus y ningún distractor forma otro

El filtro de conjugación usa el propio parser como oráculo de gramaticalidad: es la misma herramienta que localizó el hueco, aplicada a la frase sustituida. El de separables usa la atestiguación en el corpus como proxy de existencia del verbo — conservador pero verificable (véase §6, limitaciones).

4. Conteos del corpus (calculados de gramatica.json)

El generador emite **157 ejercicios** repartidos en 4 temas, con tope de 40 por tema y selección estratificada round-robin entre fuentes (cota de 12 candidatos por fuente antes de estratificar).

4.1 Ejercicios por tema y nivel

Tema	Total	Principiante	Intermedio	Avanzado	Fuentes
Declinación del artículo	40	5	27	8	12
Preposición y caso	40	6	20	14	11
Conjugación del verbo	40	8	25	7	12
Verbos separables	37	2	11	24	9

Sin la estratificación, el tope de 40 se llenaba íntegramente con la primera fuente en orden alfabético (Immensee) y ni una frase de principiante/intermedio aportaba ejercicios; el round-robin reparte entre 9–12 fuentes por tema.

4.2 Distribución de respuestas (declinación)

Caso (según spaCy)	Ejercicios
Nominativo	20
Acusativo	10
Dativo	7
Genitivo	3

Formas: «der» ×12, «die» ×11, «das» ×7, «den» ×6, «dem» ×2, «des» ×2. La distribución refleja el corpus (narrativa en pasado, mucho nominativo/acusativo); no se fuerza el balance para no fabricar frases artificiales.

4.3 Preposiciones y separables

Preposiciones más preguntadas: «mit» ×15, «für» ×8, «zu» ×5, «aus» ×4, «von» ×4, «durch» ×1, «ohne» ×1, «um» ×1.

Prefijos separables más preguntados: «auf» ×7, «an» ×5, «aus» ×3, «heraus» ×2, «zurück» ×2, «herein» ×2, «hinein» ×2, «vor» ×1.

Verbos más preguntados en conjugación: «sein» ×13, «gehen» ×8, «kommen» ×3, «singen» ×2, «werden» ×2, «wollen» ×2, «lassen» ×2, «lesen» ×1.

5. Coste computacional

Fase	Coste
Parseo del corpus	Una pasada de spaCy por frase corta (≤ 18 tokens); las largas se descartan con un prefiltro por espacios antes de parsear
Coseno	$O(C(r))$ productos escalares de dimensión 300 por hueco; $ C \leq 28$
Filtro de conjugación	El más caro: un re-parseo por candidato validado. Se valida en orden de coseno descendente y se corta al llegar a $k=3 \rightarrow \sim 3-6$ re-parseos por hueco
Total	~ 1 minuto en CPU para todo el corpus; el frontend no paga nada de esto (consume JSON estático por dynamic import)

6. Limitaciones y trabajo futuro

Semántica no modelada. En separables la elección del prefijo es en parte semántica (aufmachen/zumachen son ambos reales); el filtro de atestiguación garantiza que los distractores no formen verbo real, pero el ejercicio sigue apoyándose en la pista (que da el verbo completo). **Atestiguación como proxy.** Que un verbo no esté en el léxico del corpus no implica que no exista en alemán; el criterio es conservador por el lado correcto (nunca valida un distractor real atestiguado), pero podría descartar distractores legítimos. **Parser como oráculo.** El filtro de concordancia hereda los errores de spaCy; en frases cortas y simples (las que se seleccionan) su precisión morfológica es alta. **Futuro:** más temas (verbo en 2ª posición, Konjunktiv), balance de casos por muestreo dirigido, ejercicios en inglés, y progreso persistente por tema (localStorage) para conectar con el repaso espaciado.