

Reporte de métricas

Plataforma de idiomas — sistema de lectura y pipeline de PLN

Métricas cuantitativas para la memoria de tesis, calculadas sobre el contenido y el código reales del proyecto.

1. Corpus

El corpus consta de **30 lecturas** (3 principiante, 7 intermedio, 20 avanzado), incluyendo **2 libros** completos troceados en 20 partes.

Métrica (texto en alemán)	Valor
Frases	1,811
Tokens de palabra (ocurrencias)	30,302
Tipos (formas distintas)	5,384
Razón tipo/token (TTR)	0.178
Longitud media de frase (palabras)	16.7

La TTR baja es esperable en un corpus con dos novelas: mucho vocabulario se repite; los tipos distintos son los que el léxico debe cubrir.

2. Cobertura y densidad de traducción por palabra

La **cobertura** es el porcentaje de *tipos* (formas distintas) con traducción; la **densidad** práctica que ve el usuario es aún mayor porque las formas frecuentes (que más se tocan) están cubiertas.

Nivel	Tipos con traducción / totales	Cobertura
Principiante	117 / 117	100%
Intermedio	789 / 789	100%
Avanzado (libros)	11568 / 12181	94%

Principiante e intermedio alcanzan el **100%** gracias a la semilla curada y a los overrides por lectura; los libros avanzados quedan en torno al 92% (los fallos restantes son verbos fuertes que spaCy no lematiza y compuestos raros).

3. Contribución de cada capa del traductor (alemán)

Descomposición de las traducciones del léxico alemán según la capa que las resolvió (directo FreeDict, cadena por inglés, o cabeza de compuesto). Muestra cuánto aporta cada técnica.

Capa	Entradas	% de las traducidas
Directo (FreeDict deu-spa)	3,738	76%

Capa	Entradas	% de las traducidas
Cadena deu-eng -> eng-spa	660	13%
Cabeza de compuesto	490	10%
Total con traducción (de)	4,888	100%

Léxico total: **5,779 entradas** (5,374 de + 405 en); inglés->español cubre 405/405. La **cadena por inglés** es la que más eleva la cobertura del alemán, a costa de un salto extra (marcado en la app).

4. Desambiguación de verbos separables (overrides por lectura)

El léxico global no puede distinguir formas dependientes del contexto (p. ej. *nahm* = *annehmen* vs *nehmen*). Se añadieron **19 overrides por lectura** en 7 textos de principiante/intermedio, curados a mano y verificados frase a frase, que el frontend prioriza sobre el léxico global.

5. Traducción por oración (por libro)

Libro	Autor	Partes	Frases	Método	Alineación
Immensee	Theodor Storm	10	842	opus-mt (MT offline)	100%
Die Verwandlung	Franz Kafka	10	864	Gemini (LLM)	100%

Ambos libros tienen alineación frase a frase **1:1 verificada** por el validador del importador (si el conteo no cuadra, no se escribe nada).

6. Calidad del transformer (MT) frente al LLM de referencia

Se tradujo la **Parte 1 de Die Verwandlung** (90 frases) con **opus-mt** y se comparó con la traducción de **Gemini** (tomada como referencia). Métricas de similitud automática:

Métrica	Valor	Interpretación
chrF (F-score de n-gramas de carácter, beta=2)	61.9	0-100; mide solape de caracteres. Traducciones aceptables suelen dar 40-60.
F1 de tokens (solape de palabras)	62.7	0-100; solape léxico bruto con la referencia.

Lectura de los números: la MT recupera una parte sustancial del contenido de la referencia, pero **no es una medida de calidad absoluta**: Gemini no es una verdad de oro, y dos traducciones correctas pueden diferir mucho en palabras. Cualitativamente la MT comete errores semánticos que el LLM no (p. ej. *bestäubt* -> “polinizados” en vez de “polvoriento”; *Ungeziefer* -> “bestia” en vez de “insecto”). Conclusión: la MT es **viable y totalmente automática**, pero por debajo del LLM en fidelidad.

7. Motor algorítmico (pruebas)

El núcleo de lógica pura se prueba con **Vitest: 17 casos** en 3 archivos.

Módulo	Qué verifican las pruebas
board.js (LCG + tablero)	Determinismo: misma semilla -> mismo tablero; distribución exacta 9/8/7/1 de colores; semillas distintas -> tableros distintos; parseo de semilla.
bolsa.js	Alta sin duplicar; regla “palabra existente conserva su estado”; inmutabilidad; normalización con acentos/umlauts.
progreso.js	Marcar/consultar lecturas completadas.

8. Resumen de volumen

Concepto	Cantidad
Lecturas (total)	30
Libros completos	2 (immensee, verwandlung)
Frases de lectura (de)	1,811
Entradas de léxico	5,779
Overrides por lectura (separables)	19
Idiomas	3 (es, en, de)

Métricas calculadas automáticamente por docs/generar_reporte_metricas.py sobre el estado actual del repositorio. chrF/F1 implementados sin dependencias externas.